

КОНКУРС СБЕРИНДЕКСА · НАПРАВЛЕНИЕ «КЛАСТЕРИЗАЦИЯ»

Типы локальных экономик муниципалитетов

Техническое приложение в слайдах: данные, методы, проверки устойчивости, динамика и рынок труда — всё, что не вошло в основной отчёт

Дополнение к методологическому отчёту · версия от 8 октября 2026 г.

Подробности и проверки, на которые ссылается отчёт

1 · Данные и сеть

Выборка, признаки узлов, четыре понятия близости, направленные связи

2 · Методы и выбор

KEFRiN на синтетике, сетка из 280 вариантов, конфликт индексов, правило выбора

3 · Устойчивость

Устойчивость типов, перезапуски, чувствительность, вклад сети, описания, Росстат

4 · Динамика

Квартальное присвоение, скользящие окна, кандидаты на переход и их проверка

5 · Рынок труда

Подготовка данных Росстата, шесть типов, карта расхождений, разобранные случаи

6 · Проверки

Что изменилось после исправлений, ограничения, воспроизводимость

Выборка: 2 016 из 2 190 МО с полным рядом

2 016

МО с полным рядом: 24 месяца по всем категориям расходов — базовая выборка

174

МО выпали, и они другие: медиана расходов 22 821 ₽ против 24 427 ₽, доля маркетплейсов 12,2% против 14,6%. СберИндекс публикует оценку только при достаточном качестве — пропуски не случайны

Покрытие и особенности архива

Данные	МО из 2 016
Индекс доступности рынков	2 004
Расстояния по автодорогам	2 006
Расстояния по железным дорогам	1 262

- Железнодорожные пары записаны в обе стороны — дубли объединены
- 148 пар с нулевым расстоянием (общий центр) — заменено на 1 км
- 3 МО объединены с соседями в 2024 г. — взята последняя версия справочника

Признаки узлов: три блока равного веса

Структура

Доли пяти категорий и «прочего» за 24 месяца → центрированные лог-отношения (CLR); каждая координата стандартизована

Уровень

Лог-разность расходов МО и медианы всех МО в том же месяце: убирает общий рост и календарные пики

Динамика

Рост 2024/2023, летний и декабрьский пики сверх общих, волатильность без тренда, сдвиг к маркетплейсам

ВЕСА

Каждый блок делится на $\sqrt{\text{число признаков}}$: блоки весят одинаково


ЗАКОН ЭНГЕЛЯ ПО МО

Уровень расходов и доля еды: $-0,77$; уровень и доля общепита: $+0,84$

Четыре понятия близости дают почти разные сети

Сеть	Рёбер	Степень	Частей
Профиль (все признаки)	14 363	14,2	1
Синхронная динамика	16 730	16,6	1
Форма траектории (DTW)	15 948	15,8	1
Автодороги	9 986	9,9	13
Мультиплекс	38 747	38,4	1

Мультиплекс = дороги + синхронная динамика + DTW, каждый слой нормирован на средний вес ребра (доли масс 23 / 39 / 37%). Сеть профиля в него не входит: она из тех же признаков, что и признаковая часть KEFRiN



Жаккар рёбер любых двух семейств $\leq 0,09$

Это различие наборов связей, а не доказательство пользы каждого слоя: польза проверена исключением слоёв

Каждая сеть связывает похожие МО, но по-своему



Модулярность Leiden против нуль-модели (20 графов с теми же степенями)

Сеть	Q	Сверх нуля	Групп
Профиль	0,693	0,447	10
Синхронная динамика	0,701	0,466	10
DTW	0,677	0,442	8
Автодороги	0,895	0,545	43
Мультиплекс	0,536	0,374	6

- По дорогам похожи структура и уровень ($I = 0,49-0,80$), слабее динамика
- У дорог самые чёткие сообщества, но 43 группы – это скорее регионы, чем типы

Столицы регионов не опережают периферию

47,5%

пар «столица — МО региона»: лучший
лаг нулевой

25,1%

столица «опережает» (лаг до
3 месяцев)

27,5%

столица «отстаёт» — почти столько же

1 532 пары, 60 регионов. Критерий Уилкоксона по регионам
 $p = 0,79$; у случайной «псевдостолицы» — 28% и 27%.

Свидетельств опережения нет, поэтому направленных рёбер
в сети нет

Сеть синхронной динамики, построенная отдельно по 2023 и
2024 гг., почти не повторяется: Жаккар рёбер 0,065. Поэтому
слой строится по всем 24 месяцам, а основная сеть статична

KEFRiN: когда сеть меняет результат

$$F = \rho \cdot \sum d(y_i, c_k) + \xi \cdot \sum d(p_i, \lambda_k)$$

Признаки МО и строка матрицы связей описываются центрами кластеров в обоих пространствах (Shalileh & Mirkin, 2022). Реализация – по статье, без чужого кода

Наша адаптация: ξ умножается на $\sum y^2 / \sum p^2$, чтобы вклады блоков сравнивались. У победителя фактический $\xi = 0,054$, у дорог – 0,76

Синтетика: ARI с истинным разбиением, средняя степень 10

Метод	Признаки	Сеть	Дополняют
k-means (признаки)	0,86	0,00	0,46
Leiden (сеть)	0,00	0,98	0,46
KEFRiN исходный	0,85	0,00	0,46
KEFRiN, выравнивание $\xi \times 1$	0,86	0,00	0,46
KEFRiN, выравнивание $\xi \times 4$	0,84	0,01	0,90
KEFRiN исходный, степень 20	0,86	0,12	0,96

На разреженной сети исходный KEFRiN совпадает с k-means. Источники объединяются при большем весе сети или более плотной сети. Мультиплекс в 3,9 раза плотнее дорог – возможная, но не доказанная причина его победы

Сетка: восемь методов, 280 вариантов

k-means

признаки

Шарообразные кластеры
одного масштаба

GMM

признаки

Много параметров; CLR-
пространство вырождено

Уорд

признаки

Чувствителен к составу выборки
и выбросам

Паттерны

порядок показателей

119 из 120 паттернов; для K —
расстояние Кемени

Leiden

сеть

Игнорирует признаки; малые
части сети — по признакам

Спектральная

сеть

Работает на главной
компоненте сети

Спектральная

признаки + сеть

Вес слоёв задаётся вручную


KEFRiN

признаки + сеть

Вес сети ξ критичен на
разреженных графах


K от 4 до 12 · Leiden — разрешение 0,02–1,0 · сетевые методы — на каждой из четырёх сетей · KEFRiN — косинус $\times \xi \in \{1, 4, 16\}$ и евклид $\times \xi \times 1$ · допустимы 251 из 280 (каждый тип $\geq 1\%$ и $\leq 60\%$ МО)

Шесть индексов качества тянут в разные стороны



Дубли: SW и CH — $\rho = 0,95$; AVI и MQ — 0,81

Признаки против сети: $|\rho| = 0,06-0,26$; W
Кендалла 0,39



$SW \leq 0,24$ у всех вариантов: профили
— континуум

Правило выбора и место каждого семейства

1 · Допустимость

Каждый тип $\geq 1\%$ и $\leq 60\%$ МО: допустимы 251 из 280

2 · Агрегирование рангов


Борда и Коупленд по шести индексам; их совпадение — не независимая проверка

3 · Устойчивость

12 лучших × 50 подвыборок по 80% МО; порог — средний ARI $\geq 0,6$

Победитель: 1-е место по AVU и 53–88-е по остальным пяти — выигрывает отсутствием провалов

Лучшее место семейства по Борда (из 251; короче — лучше)



Победитель во многом держится на индексе AVU

Правило	Победитель	Место итога	ARI с итогом
все 6 индексов	KEFRiN, мультиплекс, K = 8	1	1,00
без дублей	то же	1	1,00
без SW или без MQ	то же	1	1,00
без CH	KEFRiN, дороги, cos, K = 12	3	0,28
без S_Dbw	Уорд, K = 6	4	0,41
без AVI	KEFRiN, DTW, K = 9	4	0,43
без AVU	KEFRiN, дороги, cos, $\xi = 4$, K = 4	17	0,28
сеть оценки — ж/д	KEFRiN, дороги, cos, K = 9	4	0,33

Дублирующие индексы результат не определяют


Но первое место меняется в четырёх случаях из шести: конкретное разбиение зависит от состава критериев

Без AVU итог — лишь 17-й

УСТОЙЧИВОСТЬ

Устойчивость типов: от 0,48 до 0,91

Средний Жаккар: $\geq 0,75$ — устойчивый, $0,5-0,75$ — сомнительный, $< 0,5$ — неустойчивый



ФИНАЛИСТЫ, ARI

$K = 6: 0,81 \cdot K = 7: 0,78 \cdot K = 8$ (итог):
0,67. Шесть типов устойчивее

НАДЁЖНОСТЬ МО

Медиана 0,88; ниже 0,6 — у 275 МО,
из них 125 — «удалённые районы»

Перезапуски, столицы и путь от шести типов к восьми

10 перезапусков KEFRiN



4 — то же разбиение ($ARI \geq 0,996$), 1 — близкое (0,88), 5 — локальные минимумы с худшим критерием ($ARI\ 0,68-0,74$). Итог в лучшей найденной области, но у критерия есть близкие конкуренты

Без городов федерального значения

ARI 0,57

Пересчёт на 1 774 МО (V Крамера 0,70): столицы не задают типологию остальной страны, но влияют на её границы

Шесть → восемь

Средняя группа (562 МО) делится на «средний уровень» (324) и «удалённые районы» (211 из 270). «Северные ресурсные» (111) собраны из Севера (47), растущих городов (41) и других. Остальные типы на 95–100% лежат внутри своих

Что меняет разбиение: слои сети и геометрия признаков

KEFRiN, K = 8: что изменено	ARI с итогом	AVI	MQ	η^2 зарплаты
итог, другой seed	0,995	0,61	0,37	0,638
без слоя дорог	0,78	0,55	0,34	0,639
без синхронной динамики	0,85	0,60	0,37	0,641
без DTW	0,90	0,57	0,37	0,641
равные массы слоёв	0,77	0,60	0,36	0,635
ILR вместо раздельной стандартизации CLR	0,50	0,59	0,36	0,630

Из слоёв сильнее всего влияет дорожный

ILR перераспределяет в основном сельские типы; Москва и Крайний Север не меняются, Петербург сохраняется на 95%

η^2 зарплаты одинакова во всех вариантах

Что сеть добавляет по сравнению с k-means

Разбиение	ARI с итогом	AVI	MQ	В крупнейшей части типа	η^2 зарплаты
KEFRiN, мультиплекс, K = 8	1	0,61	0,37	41,7%	0,64
k-means, K = 7	0,81	0,53	0,33	38,1%	—
k-means, K = 8	0,63	0,49	0,33	33,5%	0,65

Крупные контрасты — из признаков

С k-means при K = 7 совпадение 0,81; связь с Росстатом та же

Сеть меняет границы

Типы плотнее в пространстве: 41,7% МО в крупнейшей связной части своего типа против 33,5%

Часть выигрыша механическая

Дороги — и в мультиплексе, и в оценке. На железных дорогах итог — 4-й из 251

Содержательная разница

Столичный кластер k-means делится на Москву и Петербург; 40 МО уходят в растущие города

Типы через формальные понятия: короткие правила

Тип	Характерное сочетание признаков	Точность / покрытие
0 · Сельские, низкие расходы	↓ доля общепита ∧ ↓ уровень расходов	0,81 / 0,66
1 · Средний уровень	↓ доля транспорта ∧ ↓ летний пик	0,67 / 0,44
2 · Растущие города	↑ доля общепита ∧ ↑↑ относительный рост	0,74 / 0,24
3 · Удалённые, сезонные пики	↓ здоровье ∧ ↑ транспорт ∧ ↑ летний пик	0,69 / 0,21
4 · Москва и Подмосковье	↑ транспорт ∧ ↑ прочее ∧ ↓↓ сдвиг к маркетплейсам	0,84 / 0,85
5 · Северные ресурсные	↓ здоровье ∧ ↑ уровень ∧ ↓ декабрьский пик	0,76 / 0,45
6 · Санкт-Петербург	↑↑ общепит ∧ ↓ летний пик ∧ ↓ декабрьский пик	0,65 / 0,47
7 · Крайний Север	↓↓ маркетплейсы ∧ ↑↑ летний пик ∧ ↑↑ волатильность	0,75 / 0,88

↑ / ↓ — верхняя / нижняя треть МО, ↑↑ / ↓↓ — крайний дециль. Точность — доля типа среди подходящих под правило, покрытие — доля типа, которую правило охватывает. Правила крупных типов устойчивы ($\Delta = 99-241$ у сельских), столичных держатся на единицах МО ($\Delta = 1$)

Росстат, не участвовавший в кластеризации: связь с типами (η^2)

Показатель Росстата	Итоговые типы	k-means, K = 8	Только дороги
log зарплаты	0,64	0,65	0,40
log фонда оплаты на жителя	0,52	0,52	0,27
log работников на жителя	0,34	0,34	0,16
доля старше трудоспособного	0,38	0,40	0,31
миграционный прирост	0,15	0,17	0,09

Сеть внешнюю содержательность не улучшает: k-means по тем же признакам даёт те же η^2

Индекс доступности рынков сильнее связан с разбиением по дорогам (0,80), но у них общая география – поэтому проверка по Росстату

Без городов федерального значения. «Только дороги» – Leiden, K = 12. η^2 – описательная мера связи; р-значения ANOVA при пространственной зависимости МО непригодны и не приводятся

Квартальное присвоение: 58–72% МО без смены типа

Сеть и прототипы типов фиксированы, признаки пересчитаны по каждому из 8 кварталов; МО-квартал идёт к ближайшему прототипу

Вес сети	Тип не менялся	Одна смена	Колебания
0 (признаки)	58%	16%	26%
0,5	66%	11%	23%
1 (основной)	68%	10%	22%
2	72%	9%	19%

89% МО сохранили годовой тип в 2024 г.; переходы — между сельскими и средними типами

9 МО Крайнего Севера «перешли» в северные ресурсные — возможный артефакт: квартальные признаки не описывают сезонность

62–84% — совпадение с отдельной кластеризацией каждого квартала

Сетевой член постоянен и сам удерживает МО в «своём» типе: только по нему воспроизводится 75% итоговых меток. Поэтому доли выше — не мера стабильности экономики

Скользящие окна: связи от окна к окну почти не повторяются

12-месячное окно	ARI с итогом	В своём типе	ARI с прошлым окном	то же, k-means
янв.–дек. 2023	0,64	84%	—	—
апр. 2023 – март 2024	0,54	76%	0,57	0,59
июль 2023 – июнь 2024	0,40	58%	0,44	0,58
окт. 2023 – сент. 2024	0,46	69%	0,46	0,53
янв.–дек. 2024	0,60	80%	0,48	0,51

Рёбра соседних окон (9 общих месяцев из 12)


Жаккар 0,20–0,23 для синхронной динамики и 0,085–0,113 для DTW: шум, динамика и построение графа не разделяются

Метки


45% МО не меняют метку во всех пяти окнах (k-means — 32%);
ARI окон 2023 и 2024 гг. — 0,52 (k-means 0,45)

Ядро держится, границы подвижны

Доля МО типа, не меняющих метку во всех пяти окнах



Кандидаты на переход 2023 → 2024



33 МО — список для проверки, а не установленные переходы

Без полугодовых контрастов k-means устойчивее (49–51%), KEFRiN — менее (37–43%): преимущество сети во времени не подтверждается

Данные Росстата: явные правила подготовки

7 показателей БД ПМО · 1 865 МО с данными о труде за оба года · 12 484 пары «ОКТМО — год» привязаны к МО. Это работники организаций без малого бизнеса по месту работы — не все занятые жители и не доход населения


Отношения — внутри года Числитель и знаменатель одного года, затем среднее по годам	Население Среднегодовое: $(P_{2023} + 2 \cdot P_{2024} + P_{2025})/4$; одиночный выброс больше 30% — пропуск	Отраслевая структура Превышение итога до 0,5 чел. на раздел — округление (112 МО-лет); сумма долей $\leq 1,00009$
Возраст Доли от суммы трёх групп; год отбрасывается при расхождении с населением больше 5% (6 МО-лет)	Городское население Ноль — только структурный (450 МО); нет ни одной строки — «нет данных» (75 МО)	Торговые объекты «Магазины» — итог строки 01 формы 1-ТОРГ (МО); подвиды к итогу не добавляются

Шесть типов рынка труда – без признаков потребления

Признаки: уровень (зарплата, работники местных организаций на жителя), отраслевая структура (CLR пяти групп ОКВЭД2), демография. Тот же порядок выбора: победил k-means, K = 6, ARI на подвыборках 0,90; лучший KEFRiN – второй (0,87)

Тип рынка труда	МО	Зарплата, Р	Работн. на 100	Старше труд.	Миграция	Отличие
Стареющая периферия	601	44 643	15	31,1%	–4,7	О–Q 53% занятых
Промышленные города	517	66 523	22	25,8%	–1,0	промышленность 27%
Аграрные районы	494	49 527	15	24,6%	–5,5	первичный сектор, отток
Спальные районы мегаполисов	181	106 391	11	26,3%	+12,6	мало рабочих мест
Добывающий Север	115	122 086	44	18,0%	–5,3	добыча 21%
Деловые районы мегаполисов	92	151 908	56	26,8%	+4,6	рыночные услуги 58%

Потребление и рынок труда совпадают частично



0,46 V Крамера


ARI 0,22 · AMI 0,27 — без городов федерального значения, 1 758 МО

Повторяют рынок труда: растущие города, Крайний Север, сельские (63–74% МО)

Не повторяют: средний уровень делится на три рынка труда

Это меры совпадения группировок, а не причинной связи: у двух типологий разные цели, и полного совпадения ждать не следует

Скопления расхождений и их устойчивость



Остаток модели расходов ($R^2 = 0,78$) — локальный I Морана на дорогах

49 995 перестановок (5 seed): у 199 из 212 МО скоплений метка одинакова во всех seed

Поправка БН: 117 / 95 МО; строже ВУ: 32 / 40; без поправки: 250 / 203

Медиана «расходы ÷ фонд оплаты» по типам потребления (без ГФЗ; в целом — 2,64)

Сельские · **3,14**

Удалённые · **2,68**

Средний уровень · **2,63**

Растущие города · **2,34**

Северные ресурсные · **1,13**

Крайний Север · **1,00**

Четыре случая, отобранных по правилу

Отбор	МО	Расходы, ₽/мес	Фонд на жителя	Расходы ÷ фонд	Работн. на жит.
«тратят меньше»	Верхнеуслонский район, Татарстан	25 564	77 592	0,33	0,47
Север, минимум	Катангский район, Иркутская обл.	37 896	342 424	0,11	2,43
«тратят больше»	Нижнеколымский район, Якутия	53 767	30 175	1,78	0,27
пригород, максимум	Приволжский район (Астрахань)	28 250	2 657	10,63	0,06

Три случая — разница учёта

Занятость и фонд учитываются по месту работы, расходы — по месту жительства: Иннополис в Верхнеуслонском районе, вахта на Верхнечонском месторождении в Катангском, Приволжский район в 14 км от Астрахани

Четвёртый — другой механизм

В Нижнеколымском районе число работников обычное, а расходы в 1,8 раза выше фонда. Возможные объяснения — арктические цены и доходы вне учтённого фонда; по этим данным их не различить

После исправления подготовки данных выводы сохранились

Ошибки первой версии нашлись при проверке: отраслевые доли усреднялись отдельно, итог «Магазины» складывался с подвидами, население – по трём датам с равными весами, LISA – 499 перестановок и один seed

Показатель	Первая версия	После исправления
МО с суммой отраслевых долей больше 1	59 (до 116,4%)	0 сверх округления
Типология труда: ARI на подвыборках	0,85	0,90; метки – ARI 0,94
Согласие с потреблением: ARI / AMI / V	0,21 / 0,27 / 0,46	0,22 / 0,27 / 0,46
R ² модели расходов / разрыва	0,77 / 0,65	0,78 / 0,66
O–Q / доступность / Север	+0,66 / +0,32 / –0,69	+0,66 / +0,31 / –0,69
Доля старше трудоспособного	+0,09 (p = 0,07)	+0,11 (p = 0,024)
Скопления «больше / меньше»	72 / 84	117 / 95

Ограничения

Расходы клиентов одного банка — модельная оценка, не весь оборот

Выборка смещена к МО с достаточным безналичным оборотом

24 месяца — короткий ряд; связи между окнами мало воспроизводятся

Разбиение зависит от правил оценки; тип «удалённые районы» неустойчив

Статистика труда — без малого бизнеса, по месту работы

Число скоплений LISA зависит от процедуры; устойчивы ядра

Дороги и в мультиплексе, и в оценке — индексы частично на стороне сети

Ошибки по 69 регионам; пространственные ошибки Conley не считались

Выводы — о муниципальных агрегатах, а не о жителях

Воспроизводимость: одна команда, побайтная сверка

18

шагов в python run_all.py, около 2 часов на 2 ядрах

98 мин

полный прогон с пустого каталога: результаты, рисунки и страница совпали побайтно

78

контрольных сумм в манифесте результатов, 0 расхождений

28

тестов: методы на синтетике, подготовка Росстата, сверка прогонов

Каждое утверждение отчёта сопоставлено с файлом результатов — раздел 12 приложения. Архив конкурса и справочник МО скачиваются по инструкции, выгрузка Росстата лежит в репозитории

github.com/shko2991/sberindex-local-economies · shko2991.github.io/sberindex-local-economies